Pruebas de hipótesis

Se sube la base de datos “kc_house_data.csv”

```
df.head()
```

	id	date	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	waterfront	view	...	grade	sqft_above	sqft_basement	yr_built	yr_ren
0	7129300520	20141013T000000	221900.0	3	1.00	1180	5650	1.0	0	0	...	7	1180	0	1955	
1	6414100192	20141209T000000	538000.0	3	2.25	2570	7242	2.0	0	0	...	7	2170	400	1951	
2	5631500400	20150225T000000	180000.0	2	1.00	770	10000	1.0	0	0	...	6	770	0	1933	
3	2487200875	20141209T000000	604000.0	4	3.00	1960	5000	1.0	0	0	...	7	1050	910	1965	
4	1954400510	20150218T000000	510000.0	3	2.00	1680	8080	1.0	0	0	...	8	1680	0	1987	

5 rows × 21 columns

Se construye el modelo de regresión

OLS Regression Results

Dep. Variable:	price	R-squared:	0.654
Model:	OLS	Adj. R-squared:	0.654
Method:	Least Squares	F-statistic:	2913.
Date:	Sat, 29 Aug 2026	Prob (F-statistic):	0.00
Time:	19:51:09	Log-Likelihood:	-2.9614e+05
No. Observations:	21613	AIC:	5.923e+05
Df Residuals:	21598	BIC:	5.924e+05
Df Model:	14		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	6.195e+06	1.38e+05	44.754	0.000	5.92e+06	6.47e+06
bedrooms	-3.931e+04	2026.602	-19.395	0.000	-4.33e+04	-3.53e+04
bathrooms	4.575e+04	3492.347	13.099	0.000	3.89e+04	5.26e+04
sqft_lot	-0.0016	0.051	-0.031	0.975	-0.102	0.099
floors	2.688e+04	3783.810	7.104	0.000	1.95e+04	3.43e+04
waterfront	5.791e+05	1.86e+04	31.072	0.000	5.43e+05	6.16e+05
view	4.324e+04	2273.166	19.020	0.000	3.88e+04	4.77e+04
condition	1.951e+04	2496.774	7.814	0.000	1.46e+04	2.44e+04
grade	1.197e+05	2249.149	53.230	0.000	1.15e+05	1.24e+05
sqft_above	160.7849	3.901	41.215	0.000	153.138	168.431
sqft_basement	167.0205	4.667	35.784	0.000	157.872	176.169
yr_built	-3570.1592	70.988	-50.292	0.000	-3709.302	-3431.017
yr_renovated	10.1596	3.914	2.596	0.009	2.488	17.831
sqft_living15	24.8733	3.600	6.909	0.000	17.816	31.930
sqft_lot15	-0.5505	0.078	-7.025	0.000	-0.704	-0.397

Omnibus:	16329.452	Durbin-Watson:	1.979
Prob(Omnibus):	0.000	Jarque-Bera (JB):	1194601.451
Skew:	3.030	Prob(JB):	0.00
Kurtosis:	38.914	Cond. No.	4.76e+06

Eliminación de variables Stepwise

```
======================================================================
PROCESO STEPWISE (Backward Elimination)
======================================================================
Eliminando 'sqft_lot' (p-valor = 0.9751)

Variables eliminadas: ['sqft_lot']
Variables retenidas: ['bedrooms', 'bathrooms', 'floors', 'waterfront', 'view', 'condition', 'grade', 'sqft_above', 'sqft_basement', 'yr_built', 'yr_renov
ated', 'sqft_living15', 'sqft_lot15']
```

Estadístico t

```python
# Estadístico t vs Región de Rechazo

print("="*70)
print("ENFOQUE 1: Estadístico t vs Región de Rechazo")
print("="*70)
print(f"Región de rechazo (α={alpha}): |t| > {t_critico:.4f}\n")

variables_eliminar_t = []
for var in modelo_completo.params.index:
    if var == 'const':
        continue
    t_val = modelo_completo.tvalues[var]
    decision = "RECHAZAR H0 (relevante)" if abs(t_val) > t_critico else "NO RECHAZAR H0 (no relevante)"
    print(f"{var:15s} | t = {t_val:8.3f} | |t| = {abs(t_val):8.3f} | {decision}")
    if abs(t_val) <= t_critico:
        variables_eliminar_t.append(var)

print(f"\nVariables a eliminar según este enfoque: {variables_eliminar_t}")
```

Valores p

```python
# ENFOQUE 2 - Valores p (significancia)

print("="*70)
print("ENFOQUE 2: Valores de significancia (valores p)")
print("="*70)
print(f"Criterio: rechazar H0 si p-valor < {alpha}\n")

variables_eliminar_p = []
for var in modelo_completo.pvalues.index:
    if var == 'const':
        continue
    p_val = modelo_completo.pvalues[var]
    decision = "RECHAZAR H0 (relevante)" if p_val < alpha else "NO RECHAZAR H0 (no relevante)"
    print(f"{var:15s} | p-valor = {p_val:.6f} | {decision}")
    if p_val >= alpha:
        variables_eliminar_p.append(var)

print(f"\nVariables a eliminar según este enfoque: {variables_eliminar_p}")
```

Intervalos de confianza

```
# Intervalos de Confianza

print("="*70)
print("ENFOQUE 3: Intervalo de Confianza al 95%")
print("="*70)
print("Criterio: si el IC contiene el 0 → NO se rechaza H0\n")

variables_eliminar_ic = []
ci = modelo_completo.conf_int()
for var in ci.index:
    if var == 'const':
        continue
    inf, sup = ci.loc[var]
    contiene_cero = (inf <= 0 <= sup)
    decision = "NO RECHAZAR H0 (no relevante)" if contiene_cero else "RECHAZAR H0 (relevante)"
    print(f"{var:15s} | IC = [{inf:10.4f}, {sup:10.4f}] | Contiene 0: {contiene_cero} | {decision}")
    if contiene_cero:
        variables_eliminar_ic.append(var)

print(f"\nVariables a eliminar según este enfoque: {variables_eliminar_ic}")
```

• Variable no relevante en las 3 pruebas: sqft_lot
  - |t| = 0.031 < 1.96 → no se rechaza H0
  - p-valor = 0.975 > 0.05 → no significativa
  - IC 95% = [-0.102, 0.099] contiene el 0

• Todas las demás variables son significativas por los tres criterios.

Interpretación de signos:
- Más metros cuadrados, mejor grado de construcción, vistas y frente al agua → sube el precio.
- Más habitaciones (controlando el tamaño) y casas más antiguas → baja el precio.